

人工智能实验报告——机器学习

姓名：陶昕璨 学号：24325242

一.实验题目

感知机算法--房价预测任务

MLP_data.csv 数据集包含五个属性，共10000条数据，其中 longitude 和 latitude 表示房子经纬度，housing_age 表示房子年龄，homeowner_income 表示房主的收入（单位：十万元），house_price 表示房子的价格。根据数据集中的四个输入属性 longitude、latitude、housing_age、homeowner_income，利用多层感知机模型预测房价 house_price，并绘制训练损失曲线、预测效果散点图以及模型评测指标对比图。

二.实验内容

1.算法原理

本实验实现的是一个用于回归任务的多层感知机（MLP）模型，网络结构为 4-32-16-1（隐藏层可修改）——后又增加搜索较优超参数机制。整体流程包括数据标准化、参数初始化、前向传播、损失计算、反向传播、参数更新和模型评估。

（1）数据预处理

为了**避免不同特征量纲差异过大导致梯度更新失衡**，实验中实现了 StandardScalerManual 类，对输入数据进行 Z-Score 标准化。对应公式如下：

$$\mu = \frac{1}{N} \sum_{i=1}^N X_i$$
$$\sigma = \sqrt{\frac{1}{N} \sum_{i=1}^N (X_i - \mu)^2}$$
$$Z = \frac{X - \mu}{\sigma}$$

预测完成后，通过逆变换恢复真实房价量纲：

$$X = Z \cdot \sigma + \mu$$

代码中对标准差为 0 的情况加入 $1e-8$ ，从而**避免除零异常**。

（2）网络初始化

由于隐藏层使用 ReLU 激活函数，如果初始化不合理，容易出现梯度消失或梯度爆炸。为此，我采用**He 初始化方法**（数学推导证明）对权重进行随机初始化：

$$W \sim N\left(0, \sqrt{\frac{2}{n_{in}}}\right)$$

其中， n_{in} 表示当前层输入神经元个数。偏置项初始化为 0，同时为每层参数额外建立与其形状一致的速度矩阵，用于后续动量优化。

（3）前向传播

前向传播的任务是将输入数据从前到后逐层映射到输出层。对于第 i 层，先进行线性变换：

$$Z_i = A_{i-1}W_i + b_i$$

若为隐藏层，则通过 ReLU 激活函数引入非线性能力：

$$A_i = \max(0, Z_i)$$

输出层对应回归任务，因此不再使用激活函数，而是直接输出线性结果：

$$A_L = Z_L$$

在计算过程中，每一层的线性输出 z 和激活输出 a 都会缓存到 `self.cache` 中，以便在反向传播时使用。

(4) 损失函数与反向传播

本实验选择均方误差MSE作为损失函数：梯度平滑、实现简单，但对离群点特别敏感

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (y_{\text{pred}} - y_{\text{true}})^2$$

对输出层结果求导，可得到损失函数相对于网络输出的梯度：

$$\frac{\partial L}{\partial A_L} = \frac{2(y_{\text{pred}} - y_{\text{true}})}{N}$$

然后依据链式法则，从输出层开始向前逐层传播误差。输出层由于没有激活函数，故有：

$$dZ_L = dA_L$$

隐藏层需要乘上 ReLU 的导数：

$$\text{ReLU}'(Z) = \begin{cases} 1, & Z > 0 \\ 0, & Z \leq 0 \end{cases}$$

$$dZ_i = dA_i \odot \text{ReLU}'(Z_i)$$

进一步可得到权重和偏置的梯度：

$$\frac{\partial L}{\partial W_i} = A_{i-1}^T \cdot dZ_i$$

$$\frac{\partial L}{\partial b_i} = \sum dZ_i$$

同时误差继续向前传播：

$$dA_{i-1} = dZ_i W_i^T$$

这样便完成了从输出层到输入层的梯度回传。

(5) 参数更新策略

本实验采用基础梯度下降+动量思想，减弱震荡、加快收敛。其更新公式为：

$$v_{\text{new}} = \beta v_{\text{old}} + \eta \frac{\partial L}{\partial W}$$

$$W_{\text{new}} = W_{\text{old}} - v_{\text{new}}$$

其中， $\beta = 0.9$ 为动量系数， η 为学习率。除动量外，训练过程中还加入了学习率衰减策略和 Mini-Batch（小批量数据）训练机制，使模型在训练后期更加稳定，也提高了整体训练效率。

(6) 评估指标

在测试阶段，实验从多个角度评价回归性能，采用的指标包括：

均方误差：

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (y_{\text{true}} - y_{\text{pred}})^2$$

均方根误差：

$$\text{RMSE} = \sqrt{\text{MSE}}$$

平均绝对误差：

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |y_{\text{true}} - y_{\text{pred}}|$$

决定系数：

$$R^2 = 1 - \frac{\sum (y_{\text{true}} - y_{\text{pred}})^2}{\sum (y_{\text{true}} - \bar{y})^2}$$

其中，MSE、RMSE 和 MAE 越小越好， R^2 越接近 1 说明模型拟合效果越好。

2.关键代码展示

(1) 标准化类 StandardScalerManual

```
class StandardScalerManual:
    """实现Z-Score标准化，防止特定特征主导梯度"""
    def __init__(self):
        self.mean = None
        self.std = None

    def fit(self, X):
        self.mean = np.mean(X, axis=0) #均值
        self.std = np.std(X, axis=0) #标准差
        self.std[self.std == 0] = 1e-8 # 防止除以0
        return self

    def transform(self, X):
        return (X - self.mean) / self.std

    def fit_transform(self, X):
        self.fit(X)
        return self.transform(X)

    def inverse_transform(self, X_scaled):
        return X_scaled * self.std + self.mean
```

(2) MSE 损失函数

```
class LossFunctions:
    @staticmethod
    def mse(y_true, y_pred): # 均方差损失
        loss = np.mean((y_pred - y_true) ** 2)
        grad = 2.0 * (y_pred - y_true) / y_true.shape[0]
        return loss, grad
```

(3) MLP 类：

- 初始化

```

def __init__(self, layer_sizes):
    self.num_layers = len(layer_sizes)
    self.params = {} # 保存权值和偏置
    self.grads = {} # 保存导数
    self.velocities = {} # 保存momentum速度

    np.random.seed(42)
    for i in range(1, self.num_layers):
        weight_key = f"W{i}"
        bias_key = f"b{i}"
        # He初始化
        self.params[weight_key] = np.random.randn(layer_sizes[i - 1], layer_sizes[i]) * np.sqrt(
            2.0 / layer_sizes[i - 1]
        )
        self.params[bias_key] = np.zeros((1, layer_sizes[i]))
        self.velocities[weight_key] = np.zeros_like(self.params[weight_key])
        self.velocities[bias_key] = np.zeros_like(self.params[bias_key])

```

- 激活函数

```

def relu(self, Z):
    return np.maximum(0, Z)

def relu_derivative(self, Z):
    return (Z > 0).astype(float)

```

- 前向传播 forward()

```

def forward(self, X):
    self.cache = {"A0": X} # 便于反向传播
    A = X

    # 隐藏层计算
    for i in range(1, self.num_layers - 1):
        Z = np.dot(A, self.params[f"W{i}"]) + self.params[f"b{i}"]
        A = self.relu(Z)
        self.cache[f"Z{i}"] = Z
        self.cache[f"A{i}"] = A

    # 输出层计算
    last = self.num_layers - 1
    Z = np.dot(A, self.params[f"W{last}"]) + self.params[f"b{last}"]

    self.cache[f"Z{last}"] = Z
    self.cache[f"A{last}"] = Z
    return Z

```

- 反向传播 backward()

从损失函数输出的梯度 d_{out} 出发，按层逆序求解每层的 dz 、 dw 和 db ，并利用当前层权重矩阵的转置将误差继续传递到前一层。整个过程严格遵循链式法则。

```

def backward(self, d_out):
    last = self.num_layers - 1
    dA = d_out

    for i in range(last, 0, -1):
        if i == last:
            dZ = dA
        else:
            dZ = dA * self.relu_derivative(self.cache[f"Z{i}"])

        A_prev = self.cache[f"A{i - 1}"]
        self.grads[f"W{i}"] = np.dot(A_prev.T, dZ)
        self.grads[f"b{i}"] = np.sum(dZ, axis=0, keepdims=True)
        dA = np.dot(dZ, self.params[f"W{i}"].T)

```

- 参数更新 `update_params_gd()`

本部分在传统梯度下降公式基础上加入动量速度 `self.velocities`，使每次更新不仅依赖当前梯度，也参考上一轮的变化方向，从而在训练中表现出更好的稳定性。

```

def update_params_gd(self, current_lr, momentum=0.9):
    """
    梯度下降 + 优化策略
    """
    for i in range(1, self.num_layers):
        for p in ['W', 'b']:
            key = f'{p}{i}'
            grad = self.grads[key]

            # 引入动量 Momentum
            self.velocities[key] = momentum * self.velocities[key] + current_lr * grad

            # W = W - v
            self.params[key] -= self.velocities[key]

```

(4) 主函数

主函数负责数据加载、预处理、模型构建与训练调度。具体流程如下：

- 读取数据（未成功提供模拟数据）并按训练/验证集（8:2）划分，对特征进行标准化处理以加速收敛
- 根据 `layer_sizes`、`lr`、`momentum` 等实例化模型（`RawMLP` 或 `MLP`）；
- 采用变换学习率和小批次策略
 - 学习率衰减：即在训练初期保持较大学习率，使模型能够快速下降；在训练后期逐步减小学习率，使参数更新更加平稳，从而减少震荡并提高收敛精度。
 - Mini-Batch训练：即每次只使用一个小批量样本计算梯度并更新参数。这样做既比全量训练更高效，也比单样本随机梯度下降更稳定，同时还能利用小批次带来的随机扰动帮助模型跳出局部不良区域。
- 在训练循环中使用带动量的 SGD 更新参数，每轮记录训练损失并在验证集上评估性能；

```

for epoch in range(epochs):
    # 优化策略 2: 学习率衰减
    current_lr = initial_lr * (0.8 ** (epoch // 50))

    # 优化策略 3: 小批量数据
    # 打乱数据并切分为小批次, 引入随机噪声帮助跳出局部最优
    permutation = np.random.permutation(n_samples)
    X_train_shuffled = X_train_scaled[permutation]
    y_train_shuffled = y_train_scaled[permutation]

    epoch_loss = 0
    for i in range(0, n_samples, batch_size):
        X_batch = X_train_shuffled[i:i+batch_size]
        y_batch = y_train_shuffled[i:i+batch_size]

        y_pred_scaled = model.forward(X_batch)

        loss, grad_y = LossFunctions.mse(y_batch, y_pred_scaled)
        epoch_loss += loss * X_batch.shape[0]

        model.backward(grad_y)
        model.update_params_gd(current_lr=current_lr, momentum=0.9)

    epoch_loss /= n_samples
    loss_history.append(epoch_loss)

```

(5) 回归模型测评 Metrics

```

class Metrics:
    @staticmethod
    def regression_report(y_true, y_pred):
        mse = np.mean((y_true - y_pred) ** 2) # 均方误差
        rmse = np.sqrt(mse) # 均方根误差
        mae = np.mean(np.abs(y_true - y_pred)) # 平均绝对误差 MAE
        ss_tot = np.sum((y_true - np.mean(y_true)) ** 2)
        ss_res = np.sum((y_true - y_pred) ** 2)
        r2 = 1 - (ss_res / (ss_tot + 1e-8)) # 决定系数R²: 衡量模型拟合程度, 范围0~1, 越接近1拟合越好
        return mse, rmse, mae, r2

```

(6) 指标可视化对比

在画出损失曲线和“真实值-预测值”散点图基础上, 实验增加了评测指标可视化对比图。将 MLP 与“均值基线模型”(始终预测训练集房价平均值的简单模型) 进行对比。

```

# 6. 模型评估与系统指标测试
y_test_pred_scaled = model.forward(X_test_scaled)
# 将预测值反标准化回真实的房价数值
y_test_pred = scaler_y.inverse_transform(y_test_pred_scaled)

# 提取系统指标
current_mem, peak_mem = tracemalloc.get_traced_memory()
tracemalloc.stop()
time_total = time.perf_counter() - time_start_total

# 计算算法指标
mse, rmse, mae, r2 = Metrics.regression_report(y_test, y_test_pred)
baseline_pred = np.full_like(y_test, np.mean(y_train))
baseline_mse, baseline_rmse, baseline_mae, baseline_r2 = Metrics.regression_report(y_test, baseline_pred)

```

后面我觉得不是很必要, 删除了与“均值基线模型”的对比。

3.创新点&优化

创新点：

(1) He 初始化配合 ReLU 激活函数

(2) Momentum 动量优化

(3) 学习率衰减机制

(4) Mini-Batch 训练方式

优化：

(1)尝试用遗传算法

来寻找最优配置——网络层数（layer_sizes）、学习率（lr）、动量因子（momentum）

但是由于代码太长（有400多行），这里给出主要部分的实现思路以及主函数实现，感觉过于复杂且时间成本大幅度提高，遂未采用

```
if __name__ == "__main__":
    print("MLP regression with GA hyperparameter search\n")

    tracemalloc.start()
    total_start = time.perf_counter()

    X, y = load_dataset()
    X_train, X_val, X_test, y_train, y_val, y_test = split_dataset(X, y, random_seed=42)
    data_bundle = prepare_features(X_train, X_val, X_test, y_train, y_val, y_test)

    # 创建遗传算法搜索器
    searcher = GeneticHyperparameterSearch(
        population_size=10,
        generations=5,
        coarse_epochs=40,
        final_epochs=250,
        batch_size=256,
        elite_size=3,
        tournament_size=3,
        mutation_rate=0.25,
        top_k_finalists=3,
        random_seed=42,
    )

    # 运行遗传算法，筛选最优超参数
    ga_start = time.perf_counter()
    finalists, coarse_results = run_ga_search(data_bundle, searcher)
    ga_time = time.perf_counter() - ga_start
    # 对最优参数做完整训练
    final_runs = refine_finalists(data_bundle, finalists, searcher)
    best_run = final_runs[0]

    current_mem, peak_mem = tracemalloc.get_traced_memory()
    tracemalloc.stop()
    total_time = time.perf_counter() - total_start

    baseline_pred = np.full_like(data_bundle["y_test_raw"], np.mean(data_bundle["y_train_raw"]))
    baseline_mse, baseline_rmse, baseline_mae, baseline_r2 = Metrics.regression_report(
        data_bundle["y_test_raw"],
        baseline_pred,
    )
```

a. 遗传算法类：GeneticHyperparameterSearch

- 种群：随机生成一批超参数——[学习率, 动量值, 隐藏层节点数] 组合

- 适应度函数：运行现有的 RawMLP 训练 100 轮，最后在验证集上算出的 R^2 评分。 R^2 越高，说明这组超参数越强，适应度就越高。
- 精英保留
- 交叉：父母各给一半基因，生成孩子
- 变异：随机小改动，避免算法陷入局部最优

其中，超参数优化范围：

学习率 lr: 0.003 ~ 0.03

动量 momentum: 0.75 ~ 0.98

隐藏层 1: 16/24/32/48/64

隐藏层 2: 8/16/24/32 (永远 ≤ 第一层)

b. 数据处理部分

- 作用：加载数据 → 划分训练集 → 标准化
- 特征：经纬度、房龄、收入
- 标签：房价
- 划分：70% 训练 / 15% 验证 / 15% 测试

c. 模型训练：train_model

- 训练逻辑：
 - 网络结构：4 → hidden1 → hidden2 → 1
 - 学习率会自动衰减（每 50 轮变小）
 - 训练发散（崩溃）会直接停止，标记失败
 - 训练完返回验证集 R^2 分数（越高越好）

d. 主流程：run_ga_search + refine_finalists

- 粗训练（快）
 - 每代训练 40 轮
 - 快速筛选好的超参数
 - 遗传算法进化 5 代
- 精训练（准）
 - 选出最好的 3 组超参数
 - 用 250 轮充分训练
 - 在测试集上评估最终效果
 - 最后输出：最优超参数，测试集 MSE、RMSE、MAE、 R^2 ，运行时间、内存占用，与均值基线对比

模型拟合效果对比

模型	MSE	RMSE	MAE	R^2
原始 MLP	3723911615.21	61023.86	41605.56	0.7261
GA 优化 MLP	3209614869.39	56653.46	38541.53	0.7619
均值基线模型	13489186457.00	116142.96	90317.16	-0.0007

从表中可以看出，GA 优化后的 MLP 在各项回归指标上**均优于原始模型**

运行效率对比

模型	总运行耗时	峰值内存占用	说明
原始 MLP	2.383 s	3.82 MB	只训练一次固定参数模型
GA 优化 MLP	42.672 s	5.59 MB	需要多次训练候选模型并筛选最优参数

从运行效率来看，GA 优化版本的耗时**明显高于**原始 MLP，计算成本显著上升。

(2) 简单搜索较优神经网络参数

用较少轮数做粗搜索，只保留前几组表现最好的参数，再对这些候选参数做完整 训练，最后再汇报测试集 R^2 、MSE、训练。

- 生成候选数 build_candidate_configs

```
def build_candidate_configs(n_configs=10, random_seed=42):
    np.random.seed(random_seed)

    hidden1_choices = [16, 24, 32, 48, 64]
    hidden2_choices = [8, 12, 16, 24, 32]

    lr_choices = [0.003, 0.005, 0.008, 0.010, 0.012, 0.015]
    momentum_choices = [0.85, 0.88, 0.90, 0.92, 0.95]
    batch_size_choices = [16, 32, 64]
    l2_choices = [0.0, 1e-5, 1e-4, 1e-3]

    configs = []

    for _ in range(n_configs):
        hidden1 = int(np.random.choice(hidden1_choices))
        hidden2 = int(np.random.choice(hidden2_choices))

        if hidden2 > hidden1:
            hidden2 = max(8, hidden1 // 2)

        config = {
            "layer_sizes": [4, hidden1, hidden2, 1],
            "initial_lr": float(np.random.choice(lr_choices)),
            "momentum": float(np.random.choice(momentum_choices)),
            "batch_size": int(np.random.choice(batch_size_choices)),
            "l2_lambda": float(np.random.choice(l2_choices)),
        }

        configs.append(config)

    return configs
```

- 模型评估 evaluate_model
主要是得到eval_mse, eval_r2
- 模型训练 train_with_config

```

def train_with_config(.....):
    model = RawMLP(layer_sizes=layer_sizes) # 创建模型
    loss_history = [] # 保存loss
    val_r2_history = [] # 保存验证集R^2
    n_samples = X_train_scaled.shape[0] # 样本数

    # 开始计时
    time_train_start = time.perf_counter()

    loss_fn = LossFunctions.get_loss(loss_name, delta=huber_delta)

    early_stopper = EarlyStopping(
        patience=early_stopping_patience,
        min_delta=early_stopping_min_delta,
    )

    # 训练 epoch 轮
    for epoch in range(epochs):
        current_lr = initial_lr * (0.8 ** (epoch // 50))

        # 打乱数据, MiniBatch SGD需要随机
        permutation = np.random.permutation(n_samples)

        X_train_shuffled = X_train_scaled[permutation]
        y_train_shuffled = y_train_scaled[permutation]

        epoch_loss = 0.0
        diverged = False

        # batch训练
        for i in range(0, n_samples, batch_size):
            X_batch = X_train_shuffled[i : i + batch_size]
            y_batch = y_train_shuffled[i : i + batch_size]

            y_pred_scaled = model.forward(X_batch)

            data_loss, grad_y = loss_fn(y_batch, y_pred_scaled)

            l2_penalty = model.compute_l2_penalty(l2_lambda=l2_lambda)
            loss = data_loss + l2_penalty

            # 梯度爆炸检查
            if not np.isfinite(loss) or not np.all(np.isfinite(grad_y)):
                diverged = True
                break

            epoch_loss += loss * X_batch.shape[0]
            model.backward(grad_y)
            model.update_params_gd(current_lr=current_lr, momentum=momentum, l2_lambda=l2_lambda)

        if diverged:
            return {
                "model": model,
                "loss_history": loss_history,
                "val_r2_history": val_r2_history,
                "eval_mse": np.inf,
                "eval_r2": -np.inf,
                "train_time": time.perf_counter() - time_train_start,
                "best_epoch": early_stopper.best_epoch,
                "stopped_early": False,
            }

    # 每个epoch结束评估验证集

```

```

epoch_loss /= n_samples
loss_history.append(epoch_loss)
_, val_r2, _ = evaluate_model(model, X_eval_scaled, y_eval, scaler_y)
val_r2_history.append(val_r2)
early_stopper.update(val_r2, epoch + 1, model)

if verbose and (epoch + 1) % 50 == 0:
    print(
        f"[{optimizer_name.upper()}] Epoch [{epoch + 1}/{epochs}] | "
        f"Train Loss ({loss_name.upper()}): {epoch_loss:.4f} | Val R2: {val_r2:.4f}"
    )

if early_stopper.should_stop:
    if verbose:
        print(
            f"[{optimizer_name.upper()}] Early stopping at epoch {epoch + 1}, "
            f"best Val R2 = {early_stopper.best_score:.4f} "
            f"(epoch {early_stopper.best_epoch})"
        )
    break

train_time = time.perf_counter() - time_train_start
early_stopper.restore_best_weights(model)

eval_mse, eval_r2, _ = evaluate_model(model, X_eval_scaled, y_eval, scaler_y)
# 返回训练结果字典
return {
    "model": model,
    "loss_history": loss_history,
    "val_r2_history": val_r2_history,
    "eval_mse": eval_mse,
    "eval_r2": eval_r2,
    "train_time": train_time,
    "best_epoch": early_stopper.best_epoch,
    "stopped_early": early_stopper.should_stop,
}

```

- 在主函数中进行粗训练和Top_k完整训练

```

# 候选超参数数量
n_config=10;
candidate_configs = build_candidate_configs(n_configs=10)
coarse_results = []

# -----粗搜索-----
print("\n开始粗搜索: 每组参数先训练 40 轮, 并在验证集上评估。")
for idx, config in enumerate(candidate_configs, start=1):
    train_result = train_with_config(.....)
    coarse_results.append(
        {
            "config": config,
            "val_mse": train_result["eval_mse"],
            "val_r2": train_result["eval_r2"],
            "best_epoch": train_result["best_epoch"],
        }
    )
print(
    f"候选 {idx:02d}: {config_to_text(config)} | "
    f"Val MSE={train_result['eval_mse']:.2f} | Val R2={train_result['eval_r2']:.4f} | "
    f"Best Epoch={train_result['best_epoch']}"
)

# 选出Top-K
coarse_results.sort(key=lambda item: item["val_r2"], reverse=True)
finalists = coarse_results[:top_k]

#-----完整训练Top-K-----
print("\n粗搜索最优 Top 候选: ")
for rank, item in enumerate(finalists, start=1):
    print(
        f"Top {rank}: {config_to_text(item['config'])} | "
        f"Val R2={item['val_r2']:.4f} | Best Epoch={item['best_epoch']}"
    )

best_search_result = None
print("\n开始完整训练 Top 候选...")
for rank, item in enumerate(finalists, start=1):
    config = item["config"]
    finalist_result = train_with_config(.....)
    # 测试集评估
    test_mse_candidate, test_r2_candidate, _ = evaluate_model(
        finalist_result["model"],
        X_test_scaled,
        y_test,
        scaler_y,
    )
    print(
        f"Finalist {rank}: {config_to_text(config)} | "
        f"Test MSE={test_mse_candidate:.2f} | Test R2={test_r2_candidate:.4f}"
    )
    print(f" Early stopping best epoch: {finalist_result['best_epoch']}")
    search_result = {
        "config": config,
        "test_mse": test_mse_candidate,
        "test_r2": test_r2_candidate,
        "train_time": finalist_result["train_time"],
        "best_epoch": finalist_result["best_epoch"],
    }
    if best_search_result is None or search_result["test_r2"] > best_search_result["test_r2"]:
        best_search_result = search_result

# 获取最佳配置

```

```
best_config = best_search_result["config"]
print(f"\nBest config: {config_to_text(best_config)}")
```

运行结果

```
=====
Training Summary
=====
Total runtime: 26.058 s
SGD+Momentum train time: 3.982 s
L2 lambda: 0.0001
Best epoch: 250
Early stopped: no
Peak memory: 15.21 MB

=====
Metrics
=====
SGD+Momentum | MSE=3375826498.31 | RMSE=58101.86 | MAE=39572.07 | R2=0.7496
=====
```

优化plus

我最初采用固定候选超参数集合进行搜索。候选参数主要根据网络规模、学习率以及动量系数的经验范围进行设计，例如隐藏层神经元数量设置为 16、24、32、48、64 等典型规模，并结合不同学习率和动量参数构建候选模型。

为了进一步提高搜索空间覆盖范围，实验曾尝试将固定候选参数替换为随机生成的超参数组合，希望通过随机搜索发现性能更优的网络结构。然而在多次实验后发现，随机搜索得到的模型在验证集和测试集上的 测评指标整体低于固定候选参数方案（可能是只随机了10个），因此最终保留了固定候选参数搜索策略。

- 当前问题规模较小。基于经验设计的候选参数已经能够覆盖大部分合理配置
- 随机搜索存在无效采样问题。随机搜索未必能够稳定采样到优质配置。

```
def build_candidate_configs():
    return [
        {"layer_sizes": [4, 16, 8, 1], "initial_lr": 0.005, "momentum": 0.85},
        {"layer_sizes": [4, 16, 16, 1], "initial_lr": 0.010, "momentum": 0.90},
        {"layer_sizes": [4, 24, 12, 1], "initial_lr": 0.008, "momentum": 0.88},
        {"layer_sizes": [4, 24, 24, 1], "initial_lr": 0.015, "momentum": 0.90},
        {"layer_sizes": [4, 32, 16, 1], "initial_lr": 0.010, "momentum": 0.90},
        {"layer_sizes": [4, 32, 32, 1], "initial_lr": 0.015, "momentum": 0.85},
        {"layer_sizes": [4, 48, 24, 1], "initial_lr": 0.020, "momentum": 0.90},
        {"layer_sizes": [4, 64, 32, 1], "initial_lr": 0.012, "momentum": 0.95},
    ]
```

运行结果


```
=====
Training Summary
=====
Total runtime: 21.560 s
SGD+Momentum train time: 4.082 s
L2 lambda: 0.0001
Best epoch: 247
Early stopped: no
Peak memory: 15.40 MB


=====
Metrics
=====
SGD+Momentum | MSE=3159306737.87 | RMSE=56207.71 | MAE=39334.68 | R2=0.7656
=====
```

(3) 绘制各特征的分布直方图+相关性可视化

- 目的：可以直观了解数据的偏态、峰度及异常值情况

输入特征与房价目标变量的分布概览






从上图可以看出，house_price 在高值区域存在明显堆积，尤其是最大值和 99% 分位数都达到 500001，说明数据中存在较明显的高价上界聚集现象。按照 IQR 方法统计，超出上界阈值 468100 的样本约有 583 条，占总样本的约 5.83%。这说明数据中确实存在一定比例的高价“异常样本”或极端样本

各输入特征与房价的线性相关系数如下表所示：

特征	与 house_price 的相关系数
longitude	0.1145
latitude	-0.2593
housing_age	0.1103
homeowner_income	0.6949

虽然直方图直观简单，但是为了更准确地评估特征与房价之间的关系，后续采用相关性热力图进行分析——热力图基于相关系数矩阵构建，能够直接展示各特征与目标变量之间的相关程度，同时还能反映特征之间的相关关系。

特征相关性热力图



(4) 使用误差函数Huber Loss:

- 原理: 在误差大时表现为对异常值钝感的 MAE, 在误差小时表现为对收敛友好的 MSE

设残差 $a = y_{true} - y_{pred}$, Huber Loss 的公式定义如下:

$$L_{\delta}(a) = \begin{cases} \frac{1}{2}a^2 & \text{for } |a| \leq \delta \\ \delta \cdot (|a| - \frac{1}{2}\delta) & \text{otherwise} \end{cases}$$

- 优点: MAE 更稳定、比 MSE 更鲁棒, 兼顾平滑性和抗异常值能力

@staticmethod

```
def huber(y_true, y_pred, delta=1.0):
    error = y_pred - y_true
    abs_error = np.abs(error)
    mask = abs_error <= delta

    quadratic = 0.5 * (error ** 2)
    linear = delta * (abs_error - 0.5 * delta)
    loss = np.mean(np.where(mask, quadratic, linear))

    grad = np.where(mask, error, delta * np.sign(error)) / y_true.shape[0]
    return loss, grad
```

同时需要增加 select_loss_function() 用于交互选择损失函数

引入 Huber Loss 后的模型结果

模型测试结果(delta=1.0)如下：

指标	数值
MSE	4037489937.34
RMSE	63541.25
MAE	42929.15
R ²	0.7005

从结果来看，当前 Huber Loss 配置下模型的 R² 出现下降，同时 MSE 、 RMSE 和 MAE 也有所变差，说明模型整体拟合效果较此前基于 MSE 损失函数的结果更弱。

(5) 早停策略

少跑很多无效 epoch，减少过拟合

- EarlyStopping，保存验证集上最优轮次对应的参数

```
# 允许20各epoch没有提升
# 提升幅度必须超过0.0001
def __init__(self, patience=20, min_delta=1e-4):
    self.patience = patience
    self.min_delta = min_delta
    self.best_score = -np.inf
    self.best_epoch = 0
    self.wait = 0 # 记录连续多少轮没有提升
    self.best_params = None
    self.should_stop = False

def update(self, score, epoch, model):
    if score > self.best_score + self.min_delta:
        self.best_score = score
        self.best_epoch = epoch
        self.wait = 0
        self.best_params = {key: value.copy() for key, value in model.params.items()}
        return True

    self.wait += 1
    if self.wait >= self.patience:
        self.should_stop = True
    return False

def restore_best_weights(self, model):
    if self.best_params is not None:
        model.params = {key: value.copy() for key, value in self.best_params.items()}
```

- train_with_config() 里，每个 epoch 结束后用验证集 R² 做监控，若连续若干轮没有提升就提前停止，并在结束前恢复到最佳权重

```
if early_stopper.should_stop:
    if verbose:
        print(
            f"[{optimizer_name.upper()}] Early stopping at epoch {epoch + 1}, "
            f"best Val R2 = {early_stopper.best_score:.4f} "
            f"(epoch {early_stopper.best_epoch})"
        )
    break
```

(6) L2正则（权重衰减）

给损失函数加惩罚，防止过拟合

为便于说明 L2 正则化的作用机制，这里先忽略动量项，仅从基础梯度下降角度分析其更新形式；在实际代码实现中，参数更新还叠加了 Momentum 机制。

- 前向传播中的 L2 正则项
- 引入 L2 正则化后，总损失函数变为：

$$L_{total} = L_{MSE} + \frac{\lambda}{2} \sum W^2$$

- 其中：
- λ 表示正则化系数，用于控制惩罚强度
 - $\sum W^2$ 表示网络中所有层权重矩阵元素平方和
 - 偏置项 b 不参与正则化
- 反向传播中的 L2：正则化 L2 正则化真正发挥作用的关键在于反向传播。由于总损失函数中额外包含了权重平方项，因此对权重 W 求偏导时，有：

$$\frac{\partial L_{total}}{\partial W} = \frac{\partial L_{MSE}}{\partial W} + \lambda W$$

将其代入梯度下降更新公式：

$$\begin{aligned} W &= W - \eta \cdot \text{grad}_{total} \\ W_{new} &= W - \eta (\text{grad}_{MSE} + \lambda W) \\ W_{new} &= (1 - \eta \lambda) W - \eta \cdot \text{grad}_{MSE} \end{aligned}$$

```
l2_penalty = 0
for l in range(1, model.num_layers):
    l2_penalty += np.sum(model.params[f'W{l}'] ** 2)

total_loss = epoch_loss + (lambd / (2 * n_samples)) * l2_penalty

def compute_l2_penalty(self, l2_lambda=0.0):
    if l2_lambda <= 0:
        return 0.0

    penalty = 0.0
    for i in range(1, self.num_layers):
        penalty += np.sum(self.params[f"W{i}"] ** 2)
    return 0.5 * l2_lambda * penalty
```

在参数更新中加入L2_lambda

```
if l2_lambda > 0:
    weight_grad = weight_grad + l2_lambda * self.params[weight_key]
```

三.实验结果及分析


优化前

1.实验结果展示示例

- (1) 训练损失随 epoch 增长整体呈下降趋势，说明模型参数在不断逼近更优解。
- 50 轮：0.2945
 - 100 轮：0.2927

- 150 轮：0.2741
- 200 轮：0.2655
- 250 轮：0.2541
- 300 轮：0.2439
- 350 轮：0.2362
- 400 轮：0.2297

(2)



- Loss 曲线图：整体趋势平稳下降，最开始由于误差大下降快
- 真实房价与预测房价的散点图：实验结果中大部分散点已经围绕参考线分布，表明模型对房价变化规律**具有较好的拟合能力**，但仍有部分点偏离较大，说明模型仍存在一定误差。

(3) 在程序运行性能方面：

- 总运行耗时：5.383 秒
- 核心训练耗时：5.353 秒
- 峰值内存占用：3.82 MB
- 测试集推理吞吐量：1262945 样本/秒


在 10000 条数据规模下依然具有较好的运行效率，内存消耗也较低。

2.评测指标展示及分析

本实验最终在测试集上得到如下回归指标：

模型	MSE	RMSE	MAE	R²
MLP 模型	3723911615.21	61023.86	41605.56	0.7261
均值基线模型	13599729304.65	116617.88	90476.50	-0.0001

模型测评指标




优化后

实验结果展示示例


MSE

loss曲线图与真实房价与预测房价的散点图



- Loss曲线
 - 损失函数在训练初期快速下降；
 - 约 20 个 Epoch 后进入稳定下降阶段；
 - 最终 Loss 收敛至约 0.20；
 - 整个训练过程较为平滑，没有出现明显震荡
- 预测结果散点图
 - 散点大部分分布在理想拟合线附近
 - 100000 ~ 350000 价格区间内预测效果较好

Huber delta=1



- Loss曲线
 - 同样能够稳定收敛
 - 收敛速度与 MSE 相近
 - 最终 Loss 值约为 0.12
- 预测结果散点图
 - 总体趋势与真实值保持一致
 - 散点离理想拟合线的离散程度更大

为了研究损失函数对房价预测性能的影响，分别采用 MSE Loss 和不同参数的 Huber Loss 进行训练，并使用测试集上的 MSE、RMSE、MAE 和 R^2 作为评价指标。实验结果如下：

损失函数	δ 参数	MSE	RMSE	MAE	R^2
MSE	-	3159306737.87	56207.71	39334.68	0.7656
Huber	0.5	4332602410.67	65822.51	44395.84	0.6786
Huber	0.8	4049450589.07	63635.29	42557.35	0.6996
Huber	1.0	3969936413.14	63007.43	42998.13	0.7055
Huber	1.4	3796142742.22	61612.85	41752.68	0.7184
Huber	1.7	3659388786.26	60492.88	41160.17	0.7285
Huber	2.0	3652335200.61	60434.55	41190.45	0.7291
Huber	2.5	4116214372.59	64157.73	43470.79	0.6947
Huber	3.0	3984351380.77	63121.72	43783.50	0.7044

四.实验总结

1. 实验整体思路

本实验围绕房价回归预测任务，使用 longitude、latitude、housing_age 和 homeowner_income 四个特征作为输入，构建多层感知机（MLP）模型预测 house_price。整体流程包括数据读取、训练集与测试集划分、Z-Score 标准化、前向传播、反向传播、参数更新、模型评估和结果可视化。

在基础模型中，我采用 4-32-16-1 的网络结构，以 MSE 作为损失函数，并使用 ReLU 激活函数、He 初始化、Mini-Batch 训练、Momentum 动量更新和学习率衰减等方法提升训练稳定性。随后，为了进一步改善模型效果，我尝试了遗传算法搜索、简单超参数搜索、固定候选参数搜索、Huber Loss、Early Stopping 和 L2 正则化等优化方法，并从预测精度、运行时间、内存占用和推理吞吐量等角度进行综合比较。

2. 主要创新点

- 根据 ReLU 特点选择 He 初始化： He 初始化，使初始权重方差与输入维度相匹配，尽量减少训练初期梯度消失或梯度爆炸问题。
- 加入 Momentum 改善参数更新方向：让参数更新参考历史梯度方向，使训练过程更加平滑。
- 设计超参数搜索而不是只依赖单一经验参数：在基础模型之外，我尝试通过遗传算法、随机候选搜索和固定候选参数搜索寻找更优网络结构、学习率和动量系数
- 结合数据分布分析选择损失函数尝试方向：通过直方图和相关性分析发现房价数据存在高价上界聚集和一定比例的极端样本，因此我尝试引入 Huber Loss，希望提高模型对异常样本的鲁棒性

3. 优化策略总结

- 标准化处理
- Mini-Batch 训练
- 学习率衰减
- Momentum 动量优化
- 超参数搜索
- Huber Loss 尝试
- Early Stopping 与 L2 正则化

4. 实验结果对比

实验方案	MSE	RMSE	MAE	R²	总运行耗时	核心训练耗时	峰值内存占用
均值基线模型	13599729304.65	116617.88	90476.50	-0.0001	—	—	—
原始 MLP	3723911615.21	61023.86	41605.56	0.7261	5.383 秒	5.353 秒	3.82 MB
GA 优化 MLP	3209614869.39	56653.46	38541.53	0.7619	42.672 秒	—	5.59 MB
简单搜索较优参数	3375826498.31	58101.86	39572.07	0.7496	26.058 秒	3.982 秒	15.21 MB
固定候选参数搜索	3159306737.87	56207.71	39334.68	0.7656	21.560 秒	4.082 秒	15.40 MB
仅搜索参数（固定超参数候选）	3579756872.51	59831.07	40327.97	0.7344	14.921 秒	2.269 秒	4.54 MB
Huber Loss (δ=0.5)	4332602410.67	65822.51	44395.84	0.6786	30.695秒	5.387秒	16.16 MB
Huber Loss (δ=0.8)	4049450589.07	63635.29	42557.35	0.6996	32.614秒	6.828秒	16.16 MB
Huber Loss (δ=1.0)	3969936413.14	63007.43	42998.13	0.7055	33.578秒	5.037秒	16.16 MB
Huber Loss (δ=1.4)	3796142742.22	61612.85	41752.68	0.7184	37.703秒	7.332秒	15.98 MB
Huber Loss (δ=1.7)	3659388786.26	60492.88	41160.17	0.7285	41.420秒	6.894秒	15.97 MB
Huber Loss (δ=2.0)	3652335200.61	60434.55	41190.45	0.7291	30.634秒	6.143秒	15.97 MB
Huber Loss (δ=2.5)	4116214372.59	64157.73	43470.79	0.6947	26.053秒	3.799秒	15.96 MB
Huber Loss (δ=3.0)	3984351380.77	63121.72	43783.50	0.7044	29.758秒	4.389秒	16.17 MB

- 进一步优化后，固定候选参数搜索方案取得了本报告中最好的预测效果，R² 达到 0.7656，MSE 降至 3159306737.87
- GA 优化 MLP 的 R² 为 0.7619，也明显优于原始 MLP，但总运行耗时达到 42.672 秒，说明遗传算法虽然能够提升模型效果，但搜索成本较高。相比之下，新增的“仅搜索参数（固定超参数候选）”方案 R² 为 0.7344，略高于原始 MLP 的 0.7261，同时总运行耗时为 14.921 秒，核心训练耗时仅 2.269 秒，峰值内存占用为 4.54 MB，推理吞吐量达到 1574307 样本/秒，体现出较好的运行效率。
- Huber Loss 的多组实验结果整体低于 MSE Loss，其中表现较好的 δ=2.0 方案 R² 为 0.7291，仍未超过固定候选参数搜索和 GA 优化方案

五.参考资料

- 1. 参考1
- 2. 参考2
- 3. 大模型：codex+gemini